

EDUGUARD

Anticiper le décrochage pour mieux accompagner les étudiants

ENSI | Projet Data Mining | 2026-2027

3 630

étudiants

30

variables

Semestre 1

moment de la prédiction

Objectif

Estimer le risque de décrochage à la fin du premier semestre, afin de proposer un soutien avant le deuxième semestre.

Données et méthode

Source UCI : 1 421 Dropout et 2 209 Graduate. Les étudiants Enrolled et les variables du semestre 2 sont exclus. Cible : Dropout=0, Graduate=1.

Split stratifié 80/20 ; standardisation et encodage dans les pipelines. Cinq algorithmes sont comparés avec optimisation des hyperparamètres.

Modèle retenu : XGBoost

XGBoost présente le meilleur F1 décrochage parmi les modèles comparés. Résultats historiques du notebook :

Modèle	AUC-ROC test	F1 décrochage
XGBoost	0,9404	0,8717
Régression logistique	0,9406	0,8587
Random Forest	0,9394	0,8387
Arbre de décision	0,9038	0,8302
KNN	0,8762	0,6591

Précision décrochage : 93,9 % | Rappel : 81,3 %

Utilisation et recommandations

Streamlit permet d'explorer les données et de tester un étudiant. FastAPI fournit les probabilités au seuil choisi, sans réentraînement.

Proposer tutorat, conseil académique ou aide financière. Le score n'est pas une certitude : la décision reste humaine. Une validation sur une autre population reste nécessaire.