EDUGUARD

Anticiper le décrochage pour mieux accompagner les étudiants

ENSI | Projet Data Mining | 2026-2027

3 630	30	Semestre 1
étudiants	variables	moment de la prédiction

Objectif

Estimer le risque de décrochage à la fin du premier semestre, afin de proposer un soutien avant le deuxième semestre.

Données et méthode

UCI : 1 421 Dropout et 2 209 Graduate. Enrolled et variables du semestre 2 exclus. Cible : Dropout=0, Graduate=1. Split stratifié 80/20 ; préparation dans les pipelines ; comparaison de cinq classifieurs.

Résultats historiques du notebook

XGBoost est retenu pour son F1 décrochage. Précision : 93,9 % ; rappel : 81,3 %. La régression logistique garde une AUC similaire et offre des coefficients plus lisibles : à conserver comme référence.

Modèle	AUC-ROC test	F1 décrochage
XGBoost	0,9404	0,8717
Régression logistique	0,9406	0,8587

Explications clés

Sur 60 profils du jeu UCI (tirage 42), les unités validées au semestre 1 et le paiement des frais dominent SHAP et la permutation. Le rôle des résultats académiques est cohérent avec l'intuition métier.
Profil de référence 0 : risque estimé 78.1 %. SHAP et LIME partagent 2/5 facteurs principaux, dont 2 de même sens. LIME R^2=0.73, écart local 8.3 points : accord à apprécier avec les limites de l'approximation locale.

Recommandations et limites

Unités validées faibles : proposer du tutorat. Difficultés de paiement : étudier une aide financière avec l'étudiant.
Âge et sexe contribuent au modèle : un audit d'équité reste nécessaire. SHAP et LIME décrivent le modèle, sans prouver une causalité ; leurs amplitudes ne sont pas directement comparables. L'échantillon explicatif peut recouper l'entraînement. Calibration et généralisation à une autre institution restent à valider. La décision reste humaine, sans sanction automatique.

Application

Streamlit : exploration, comparaison, prédiction et explications. FastAPI : probabilités et explications SHAP/LIME. Le modèle existant est conservé, sans réentraînement.