

EduGuard

Prédiction du décrochage étudiant | ENSI - Data Mining | 2026-2027

1. Problème métier

Identifier, à la fin du premier semestre, les étudiants susceptibles de décrocher pour proposer un accompagnement avant le deuxième semestre. Le score sert à soutenir une décision humaine, jamais à exclure ou sanctionner un étudiant.

2. Données et préparation

Jeu public UCI « Predict Students' Dropout and Academic Success » : 4 424 étudiants, 36 variables. Les 794 étudiants Enrolled sont exclus car leur issue finale est inconnue. Il reste 3 630 étudiants : 1 421 Dropout (39,1 %) et 2 209 Graduate (60,9 %). Cible : Dropout=0, Graduate=1. Les six variables du semestre 2 sont exclues : 30 entrées disponibles au moment de la prédiction. Split stratifié 80/20 ; standardisation, one-hot encoding et indicateurs binaires dans les pipelines pour éviter la fuite de données.

3. Modèles et résultats

Cinq modèles comparés avec GridSearchCV à cinq plis : régression logistique, arbre de décision, KNN, Random Forest et XGBoost. XGBoost est retenu pour son F1 décrochage. Résultats historiques du notebook, non recalculés pour ce rapport :

Modèle	AUC-ROC test	F1 décrochage
Régression logistique	0,9406	0,8587
XGBoost retenu	0,9404	0,8717
Random Forest	0,9394	0,8387
Arbre de décision	0,9038	0,8302
KNN	0,8762	0,6591

XGBoost : précision décrochage 0,9390 ; rappel 0,8134 ; AUC-ROC CV 0,9351.

4. Explications et analyse critique

SHAP/LIME (module 5) est volontairement différé : aucune contribution individuelle ni cohérence SHAP/LIME ne peut être affirmée. Le sexe, l'âge, la nationalité et la situation familiale sont présents parmi les entrées ; leur influence et l'équité restent à auditer. La régression logistique offre des coefficients plus lisibles et une AUC proche ; XGBoost apporte un meilleur F1 historique, au prix d'une interprétation plus difficile.

5. Recommandations et limites

Proposer tutorat, conseil académique, contact bienveillant et évaluation des aides financières. Seuil par défaut : 0,50 ; choisir les seuils sur les prédictions de validation, pas en ajustant constamment sur le test. Risque : faible <30 %, moyen 30 à <70 %, élevé à partir de 70 % ; catégories non validées statistiquement. Probabilités non établies comme calibrées ; généralisation à une autre université non démontrée. Le choix historique du modèle a consulté le test : une cohorte externe reste souhaitable.

6. Livrables et état réel

Application Streamlit locale et API FastAPI documentée et appelée par HTTP ; notebook et modèle original conservés ; dépôt GitHub avec README et captures ; ce PDF constitue le one-pager. Inférence réelle et tests automatisés validés sur Windows. Le déploiement public et le module 5 restent à terminer : le projet ne couvre donc pas encore les six modules du sujet.

Sources : UCI, jeu 697 ; résultats de prj1-datamining.ipynb. Dépôt : github.com/Soni-KR/tp1-data-mining